

PROYECTO DE ANALISIS DE VENTAS

1. Introducción y Objetivos

Se detalla ahora el trabajo realizado en un proyecto de análisis de datos enfocado en un dataset de transacciones de ventas obtenido de Kaggle. El objetivo principal es identificar patrones de compra, preferencias de productos y si el género influye en las decisiones de compra, con el fin de proporcionar insights para optimizar estrategias comerciales. Esto incluye maximizar ingresos y mejorar la experiencia del cliente. Está dirigido a gerentes de marketing y equipos de ventas.

Surgieron hipótesis para analizar:

- ¿Qué productos generan mayores ingresos?
- ¿Existe una diferencia importante en las compras según el género?
- ¿Los clientes con mayor antigüedad gastan más por transacción?
- ¿Existe un lugar con más ventas?

El trabajo se dividió en: preparación de datos, análisis exploratorio (EDA), ingeniería de atributos, entrenamiento y evaluación de modelos de machine learning, y optimización de hiperparámetros. Todo se realizó en Google Colab Notebook utilizando código Python. El dataset incluye variables de ventas desde 2019 como: ID de cliente, género, ubicación, antigüedad en meses, ID de transacción, fecha, categoría de producto, cantidad, precio promedio, costo de envío, estado de cupnes, IVA (GST), entre otras, con aproximadamente 20,000 registros.

2. Preparación de Datos

El primer paso fue importar librerías para manipular datos y visualización, como Pandas para el manejo de dataframes, NumPy para operaciones numéricas, Matplotlib y Seaborn para gráficos. Luego, se cargó el dataset desde GitHub.

Se realizó una inspección visual inicial de las primeras filas para comprender la estructura: columnas como "CustomerID", "Gender" (genero), "Location" (ciudades), "Tenure_Months" (antigüedad en meses), "Product_Category"

(categoría de producto), "Quantity" (cantidad), "Avg_Price" (precio promedio), "Delivery_Charges" (costo de envío), "Coupon_Status" (uso de cupones), "GST" (impuestos).

Comenzando la limpieza, se eliminaron filas con valores faltantes de manera simple, entendiendo que eran mínimos y no sesgaban el conjunto. A esta altura no se requirió imputación, pero se verificó la integridad del dataset, confirmando tipos de datos y eliminando columnas innecesarias.

3. Análisis Exploratorio de Datos (EDA)

El EDA se basó en visualizaciones gráficas para analizar las hipótesis y descubrir patrones en los datos.

Se calculó el ingreso total por categoría de producto (basado en cantidad multiplicada por precio promedio) y se representó en un gráfico de barras, viendo que categorías como "Nest" (productos inteligentes para el hogar) y "Gift Cards" generan los ingresos más altos, superando por mucho a otras.

Se analizó la cantidad total vendida por categoría mediante otro gráfico de barras, confirmando que "Nest" es la mayor en valor y también en cantidad, lo que indica una gran elección de estos productos modernos.

Los ingresos por ubicación geográfica se mostraron con un gráfico de barras, viendo que California, Chicago y Nueva York son los lugares con más ventas.

Un gráfico de dispersión 3D interactivo incluyó antigüedad, ingresos promedio y cantidad total por género, mostrando que las mujeres tienen mayor gasto y volumen de compras, independiente de la antigüedad.

Este EDA identificó "Nest" y "Gift Cards" como categorías clave, un mayor gasto femenino y poca influencia de la antigüedad.

4. Ingeniería de Atributos

Antes del modelado, se crearon algunas nuevas variables y se transformaron otras, preparando el camino para el machine learning.

Luego, se generó una variable de descuento aplicado, que solo aplica el descuento si el cupón fue utilizado, para poder analizar correctamente el total de venta. También se calculó el precio total por transacción (cantidad por precio promedio) y, finalmente, el ingreso total neto, incorporando el descuento, costo de envío e impuestos, que sirvió como variable objetivo para las predicciones.

Se transformó la variable categórica genero a numérica (0/1 para M/F). Para ubicación, categoría de producto y estado del cupón, se aplicó codificación one-hot, generando columnas únicas separadas para cada categoría.

Variables numéricas como antigüedad se normalizaron mediante escalado estándar, lo que mejora modelos sensibles a la escala.

Se visualizó el dataframe actualizado para verificar las transformaciones.

5. Entrenamiento y Testeo de Modelos

Se seleccionaron “features” transformadas (género codificado, antigüedad escalada, gastos escalados, ubicación, categoría y cupón) y el ingreso total como variable target. Los datos se dividieron en 80% para entrenamiento y 20% para test.

Se evaluaron dos modelos: regresión lineal para capturar relaciones lineales simples y Random Forest Regressor para manejar interacciones no lineales. Ambos incorporaron validación cruzada.

Para la regresión lineal, los valores de validación cruzada en R^2 estuvieron entre aproximadamente 0.13 y 0.21. En el test, el error cuadrático medio fue alrededor de 17,623 y el R^2 de 0.22

Para Random Forest (configuración predeterminada), los valores de validación cruzada en R^2 fueron desde -0.06 hasta 0.10, mostrando variabilidad. En test, el error cuadrático medio fue de aproximadamente 18,768 y el R^2 de 0.17

6. Optimización de Hiperparámetros

La optimización fue en Random Forest, por su potencia para manejar datos complejos. Se definieron hiperparámetros: número de estimadores (50, 100, 200), profundidad máxima (ilimitada, 10, 20) y muestras mínimas para división (2, 5, 10). Se empleó una búsqueda con validación cruzada, evaluando R^2 .

De este proceso surgieron los mejores parámetros: 200 estimadores, profundidad máxima de 10 y muestras mínimas para división de 10. El modelo ya optimizado se usó con el conjunto de entrenamiento completo. En este test, el error cuadrático

medio bajó a aproximadamente 17,118 y el R^2 mejoró a 0.24 respecto al Random Forest base, confirmando una mejor estimación.

7. Conclusiones

Las hipótesis se validaron: "Nest" y "Gift Cards" son las categorías más rentables y más vendidas, con mayor impacto en ubicaciones como California, Chicago y Nueva York. Existe una diferencia de ventas por género, con mujeres gastando más. La antigüedad no influye en el gasto. El EDA y los modelos indican que el género, la ubicación y las promociones son importantes para predecir mejoras en las ventas.

El Random Forest optimizado es el mejor modelo para pronosticar ingresos y simular estrategias comerciales.

Por todo este análisis se podría aconsejar crear campañas para mujeres en categorías líderes según localidades destacadas.